فصل ۱ ـــ مقدمه و تعریف مسئله

۱.۱ پیش‌گفتار

این پروژه به مسئله‌ی **پیش‌بینی ریزش کاربران (Churn Prediction)** در پلتفرم Stack Overflow می‌پردازد. Stack Overflow بزرگ‌ترین پلتفرم پرسش و پاسخ برنامه‌نویسی جهان است که میلیون‌ها توسعه‌دهنده از سراسر دنیا در آن مشارکت می‌کنند.

در این پلتفرم، برخلاف شبکه‌های اجتماعی معمول، **محتوا توسط کاربران خبره تولید می‌شود**. یک پاسخ‌دهنده‌ی باتجربه که سال‌ها در حوزه‌ی خاصی فعالیت کرده، ارزشی غیرقابل جایگزین دارد. از دست دادن چنین کاربرانی ضربه‌ای جدی به کیفیت پلتفرم وارد می‌کند.

بنابراین پیش‌بینی اینکه **کدام کاربران در آستانه‌ی ترک پلتفرم هستند** اهمیت استراتژیک دارد و امکان مداخله‌ی به‌موقع را فراهم می‌سازد.

۱.۲ تعریف Churn در این پروژه

۱.۲.۱ رویکرد رفتاری

در بسیاری از پروژه‌های Churn، ریزش بر اساس **وضعیت حساب** تعریف می‌شود: آیا کاربر اکانتش را حذف کرده؟ آیا اشتراکش را لغو کرده؟

اما در Stack Overflow چنین تعریفی کارساز نیست. کاربران معمولاً اکانتشان را حذف نمی‌کنند ـــ فقط **دیگر برنمی‌گردند**.

بنابراین در این پروژه، Churn به‌صورت **رفتاری (Behavioral)** تعریف شده است:

> **کاربر زمانی در معرض Churn قرار دارد که سطح فعالیت مؤثر او در یک پنجره‌ی زمانی مشخص، از یک آستانه‌ی حداقلی کمتر شود.**

این تعریف:

- مستقل از حذف حساب است
- مستقل از غیرفعال‌سازی رسمی است
- مستقیماً از **رفتار واقعی کاربر** استخراج می‌شود

۱.۲.۲ فرمول تفسیری پایه

برای کاربر u در پرسونا (گروه رفتاری) p:

$$\boxed{\text{WeightedActivity}(u, T_p) < A_p \quad \Rightarrow \quad \text{Churn Signal}}$$

که در آن:

پارامتر	تعریف	واحد
T_p	پنجره‌ی زمانی مشاهده	ثانیه
A_p	آستانه‌ی فعالیت مؤثر	بدون واحد (وزن تجمیعی)
WeightedActivity	مجموع وزن‌دار فعالیت‌های کلیدی	$\sum w_i \times \text{count}_i$

۱.۲.۳ چرا پرسونا-محور؟

کاربران Stack Overflow رفتارهای بسیار متفاوتی دارند:

نوع کاربر	الگوی فعالیت	مثال
پاسخ‌دهنده‌ی حرفه‌ای	هر روز ۳-۵ پاسخ	Jon Skeet
پرسش‌کننده‌ی گاه‌به‌گاه	هر ۲ ماه یک سؤال	دانشجوی ترم‌محور
ویراستار	ویرایش محتوای دیگران	Curator
ناظر	رأی‌دهی و نظارت	Moderator

اگر برای همه یک T_p و A_p ثابت تعریف کنیم:

- پاسخ‌دهنده‌ی حرفه‌ای که ۲ هفته نیامده ⟶ سیگنال Churn درست
- پرسش‌کننده‌ی گاه‌به‌گاه که ۲ هفته نیامده ⟶ سیگنال **اشتباه**

بنابراین پارامترها باید **پرسونا-محور** باشند.

۱.۳ پلتفرم Stack Overflow

۱.۳.۱ انواع فعالیت کاربران

در Stack Overflow، کاربران از طریق فعالیت‌های مختلف مشارکت می‌کنند:

نوع فعالیت	کد در دیتابیس	ارزش برای پلتفرم
ایجاد سؤال (Question)	`PostTypeId=1`	تولید محتوا
ایجاد پاسخ (Answer)	`PostTypeId=2`	ارزش اصلی پلتفرم
ویرایش عنوان	`PostHistoryTypeId=4`	بهبود کیفیت
ویرایش متن	`PostHistoryTypeId=5`	بهبود کیفیت
ویرایش تگ	`PostHistoryTypeId=6`	سازماندهی

نوع فعالیت	کد در دیتابیس	ارزش برای پلتفرم
Rollback	`PostHistoryTypeId=7,8,9`	کنترل کیفیت
بستن سؤال	`PostHistoryTypeId=10`	مدیریت محتوا
نظر (Comment)	جدول `comments`	تعامل اجتماعی
رأی (Vote)	جدول `votes`	❌ حذف شد

۱.۳.۲ چرا Votes از Event Log حذف شد؟

در جلسه‌ی سوم پروژه، تصمیم گرفته شد که **جدول Votes از Event Log حذف شود**. دلایل:

> «رأی‌هایی که یک پست دریافت می‌کند (Upvote / Downvote) نشانه‌ی فعالیت کاربر نیست. این رویدادها در واقع ری‌اکشن به محتوای کاربر هستند، نه رفتار خود کاربر. مخصوصاً اینکه بسیاری از انواع vote اصلاً UserId ندارند — یعنی مشخص نمی‌شود چه کسی آن رفتار را انجام داده.»

نتیجه: Votes به‌عنوان "event کاربر" وارد sequence نشد.

۱.۴ چرا مدل توالی‌محور (LSTM)؟

۱.۴.۱ محدودیت مدل‌های Snapshot

در جلسه‌ی سوم پروژه، بحث مفصلی درباره‌ی انتخاب معماری مدل انجام شد:

> «داده‌ها ماهیت توالی زمانی دارند. رفتار کاربر به مرور شکل می‌گیرد و یک snapshot آخر، رفتار را درست نشان نمی‌دهد. چک‌پوینت‌بندی ماهانه دقیقاً با ساختار sequence سازگار است.»

۱.۴.۲ مزایای LSTM

ویژگی	Snapshot Model	LSTM
نمایش رفتار	وضعیت نهایی	توالی کامل
GapTime	نادیده گرفته می‌شود	مدل‌سازی می‌شود
روند تغییر	قابل تشخیص نیست	یاد گرفته می‌شود
حافظه	ندارد	بلندمدت

> «LSTM توانایی به خاطر سپردن بخش مهمی از رفتار گذشته را دارد، GapTime. نوع اکشن‌ها و روند فعالیت کاربران در طول زمان تنها با sequence model درست است. قابل تفسیر.»

۱.۴.۳ تصمیم نهایی

در پایان جلسه‌ی سوم:

- به‌عنوان معماری اصلی انتخاب شد ✅ LSTM
- ✅ اما ابتدا سیستم Rule-based تفسیری ساخته شود (Interpretability-first)
- ✅ سپس LSTM برای بهبود دقت اضافه شود

۱.۵ داده‌های مورد استفاده

۱.۵.۱ منبع داده

داده‌ها از دیتاست رسمی Stack Overflow استخراج شده‌اند:

معیار	مقدار
تعداد کاربران هدف	~۹۲,۰۰۰
بازه‌ی زمانی	۲۰۰۸–۲۰۲۴
تعداد پرسونا	۲۰ (از پژوهش قبلی NMF)

۱.۵.۲ جداول اصلی

جدول	تعداد تقریبی رکورد	نقش
`filtered_users`	92K	کاربران با پرسونا
`filtered_posts`	چند میلیون	سؤالات و پاسخ‌ها
`posthistory`	ده‌ها میلیون	تاریخچه‌ی تغییرات
`comments`	ده‌ها میلیون	نظرات
`votes`	—	❌ حذف شد

۱.۵.۳ ساختار filtered_users

```
Id             : شناسه‌ی کاربر
ClusterNmf20   : شماره‌ی پرسونا (0–19)
CreationDate   : تاریخ ایجاد حساب
LastAccessDate : آخرین دسترسی
Reputation     : امتیاز
```

۱.۶ چالش‌های اصلی مسئله

۱.۶.۱ حجم بالای داده‌ها

> «با توجه به اینکه بخشی از داده‌ها چندین میلیون رکورد دارند و سیستم‌های فعلی توان اجرای پردازش‌های سنگین را به‌صورت مستقیم ندارند، نیاز به ابزارهای Data Processing مؤثر و کم‌هزینه مطرح شد.»

راه‌حل: استفاده از **DuckDB + Polars + Parquet** به‌جای Spark

۱.۶.۲ ناهمگنی رفتار کاربران

۲۰ پرسونای متفاوت با الگوهای رفتاری کاملاً متمایز:

- فاصله‌ی بین فعالیت‌ها متفاوت
- نوع فعالیت‌ها متفاوت
- آستانه‌ی Churn متفاوت

۱.۶.۳ Temporal Drift

در جلسه‌ی پنجم مشاهده شد:

> «پارامترهای استخراج‌شده در بازه‌های زمانی اخیر با دقت بالاتری نسبت به گذشته عمل می‌کنند. نرخ ریزش واقعی در بازه‌ی زمانی 2022 تا 2024 با افزایش بسیار قابل توجهی روبه‌رو است.»

دلایل Drift:

- دوره‌ی COVID-19 (افزایش فعالیت)
- ظهور LLMها (کاهش نیاز به پرسش)
- تغییرات پلتفرم

۱.۶.۴ عدم تعادل داده‌ها

نسبت کاربران Churnشده به فعال نامتوازن است که آموزش مدل‌ها را دشوار می‌سازد.

۱.۷ رویکرد کلی پروژه

۱.۷.۱ فلسفه‌ی Interpretability-first

پروژه با این اصل طراحی شده:

> **ابتدا سیستمی قابل توضیح بساز، سپس بر اساس محدودیت‌های مشاهده‌شده بهبود بده.**

۱.۷.۲ فازهای پروژه

```
فاز ۱: Data Engineering
        ├── MySQL → Parquet
        ├── ساخت Event Log
        └── استخراج Core Activities
                ↓
فاز ۲: Rule-based System
        ├── تخمین Tp, Ap
        ├── Grid Search + XGBoost
        └── Sliding Window Evaluation
                ↓
فاز ۳: Temporal Drift Analysis
        ├── شناسایی Drift
        ├── WA_enhanced
        └── Calibration (شکست‌خورده)
                ↓
فاز ۴: LSTM Model
        ├── Multi-Task Learning
        ├── Persona Embedding
        └── Era-aware Features
```

۱.۸ ساختار این مستند

این مستند در ۶ فصل ارائه می‌شود:

فصل	عنوان	محتوا
۱	مقدمه و تعریف مسئله	تعریف Churn، چالش‌ها، رویکرد کلی
۲	مهندسی داده و Event Log	MySQL → Parquet، ساخت Event Log
۳	سیستم تفسیری Rule-based	تخمین Tp/Ap، ارزیابی
۴	Temporal Drift و بهبودها	WA_enhanced، Calibration
۵	مدل LSTM	معماری، آموزش، ارزیابی
۶	بحث و نتیجه‌گیری	مقایسه، Trade-off، پیشنهادات

۱.۹ خلاصه‌ی فصل

در این فصل:

- ✅ مسئله‌ی Churn به‌صورت رفتاری تعریف شد
- ✅ فرمول تفسیری پایه معرفی شد: $WA(T_p) < A_p$
- ✅ دلیل انتخاب LSTM توضیح داده شد
- ✅ چالش‌های اصلی (حجم، ناهمگنی، Drift) بررسی شد
- ✅ رویکرد Interpretability-first معرفی شد

پایان فصل ۱