گزارش فنی مسیر تحلیل و پیاده‌سازی پروژه

Stack Overflow Churn Prediction

فصل ۱ — مقدمه و تعریف مسئله

۱.۱ مقدمه

۱.۱.۱ چرا Churn مهم است؟

در پلتفرم‌های آنلاین، **Churn** (ریزش کاربر) یکی از مهم‌ترین چالش‌هاست. وقتی می‌گوییم کاربری «Churn کرده»، یعنی این کاربر دیگر در پلتفرم فعالیت نمی‌کند و احتمالاً برای همیشه رفته است. این مسئله برای هر کسب‌وکار آنلاین حیاتی است، چون:

1. **هزینه‌ی جذب بالاست:** جذب یک کاربر جدید به‌طور میانگین ۵ تا ۲۵ برابر گران‌تر از نگهداری کاربر فعلی است
2. **دانش از دست می‌رود:** کاربران باتجربه اطلاعات ارزشمندی دارند که با رفتنشان از دست می‌رود
3. **اثر شبکه‌ای:** در پلتفرم‌های اجتماعی، رفتن یک کاربر ممکن است دوستانش را هم ببرد

> 💡 **مثال مفهومی:**
>
> فرض کنید کاربری مثل **Jon Skeet** با بیش از ۱ میلیون Reputation و ۳۵,۰۰۰+ پاسخ، Stack Overflow را ترک کند. این کاربر سال‌ها تجربه در C# و Java دارد و صدها هزار توسعه‌دهنده از پاسخ‌هایش استفاده کرده‌اند. جایگزین کردن چنین کاربری تقریباً غیرممکن است — شاید ۱۰ سال طول بکشد تا کاربر دیگری به این سطح برسد!
>
> در مقابل، یک کاربر جدید که فقط ۲ سؤال پرسیده، اگر برود تأثیر فوری کمتری دارد — اما همچنان یک فرصت ازدست‌رفته است. شاید این کاربر می‌توانست ۵ سال بعد Jon Skeet بعدی باشد!

۱.۱.۲ ایده‌ی اولیه: فرمول ساده

اولین قدم برای شناسایی Churn، یک قاعده‌ی ساده است:

$$\boxed{\text{Churn}(u) = \mathbb{1}\left[WA(u, T_p) < A_p\right]}$$

به زبان ساده: اگر مجموع فعالیت وزن‌دار (WA) کاربر u در دوره‌ی T_p از یک آستانه‌ی A_p کمتر باشد، آن کاربر را «در خطر ریزش» می‌دانیم.

پارامتر	معنی	مثال
WA	Weighted Activity — مجموع فعالیت‌ها با وزن‌های مختلف	پاسخ نوشتن = ۰.۳۵، نظر دادن = ۰.۰۸
T_p	Time Period — چند روز گذشته را نگاه کنیم؟	۶۰ روز، ۹۰ روز
A_p	Activity Threshold — حداقل فعالیت موردنیاز	۰.۳ (معادل تقریباً ۱ پاسخ)

مشکل فرمول ساده: این فرمول نمی‌گوید از **کِی** شروع به نگاه کردن کنیم! همچنین به کاربر فرصت نمی‌دهد — شاید کسی در مرخصی باشد.

۱.۱.۳ تکامل فرمول: اضافه کردن Grace Period و Observation Window

برای رفع مشکلات فرمول ساده، دو مفهوم اضافه کردیم:

1. **نقطه قطع (Cutoff Time) (t_c):** نقطه‌ی زمانی که از آنجا ارزیابی را شروع می‌کنیم
2. **دوره استراحت (Grace Period) (T_g):** مهلتی که به کاربر می‌دهیم (۹۰ روز) — شاید در تعطیلات باشد
3. **پنجره مشاهده (Observation Window) (T_o):** مدت زمانی که منتظر می‌مانیم تا ببینیم آیا برمی‌گردد (۳۶۵ روز)

فرمول نهایی:

$$\text{Churn}(u, t_c, T_g, T_o) = \mathbb{1}\left[|\{e : e \in \text{Events}(u) \wedge t_c + T_g < t_e < t_c + T_g + T_o\}| = 0\right]$$

به زبان ساده: کاربر u را Churn می‌دانیم اگر **بعد از مهلت ۹۰ روزه**، در **یک سال بعدی** هیچ فعالیتی نداشته باشد.

۱.۱.۴ جدول پارامترهای فرمول نهایی

پارامتر	نام	مقدار پیش‌فرض	توضیح ساده
u	کاربر	—	شناسه‌ی کاربر (مثلاً user_id = 12345)
t_c	Cutoff Time	—	تاریخی که از آن ارزیابی شروع می‌شود
T_g	Grace Period	۹۰ روز	مهلتی که به کاربر می‌دهیم
T_o	Observation Window	۳۶۵ روز	مدت انتظار برای بازگشت

> 💡 **مثال مفهومی:**
>
> کاربری در Stack Overflow آخرین پاسخش را در **آذر ۱۴۰۲** نوشته. اگر در **دی ۱۴۰۲** (۱ ماه بعد) ارزیابی کنیم، آیا Churn کرده؟ **نه!** شاید در پروژه‌ای مشغول است، شاید تعطیلات رفته، شاید امتحانات دانشگاه دارد.
>
> محسوب شود، کمی استراحت کند. بعد «Churner» به او فرصت می‌دهد که بدون اینکه (روز ۹۰) Grace Period کرده Churn از این مهلت، ۳۶۵ روز صبر می‌کنیم. اگر تا **اردیبهشت ۱۴۰۴** هنوز هیچ فعالیتی نداشت، آنگاه واقعاً.

۱.۱.۵ چرا Grace Period؟

بدون Grace Period، خطاهای زیادی رخ می‌دهد:

سناریو	بدون Grace	با Grace (90 روز)
مرخصی زایمان (3 ماه)	Churn ❌	Active ✅
تعطیلات تابستانی (2 ماه)	Churn ❌	Active ✅
پروژه‌ی جدید در کار (1 ماه)	Churn ❌	Active ✅
واقعاً ترک کرده	Churn ✅	Churn ✅

۱.۲ پلتفرم Stack Overflow به‌عنوان مطالعه‌ی موردی

۱.۲.۱ چرا Stack Overflow؟

سکوی Stack Overflow یکی از بزرگ‌ترین پلتفرم‌های Q&A برنامه‌نویسی است:

معیار	مقدار
کاربران ثبت‌نام‌شده	~۲۰ میلیون
سؤالات	~۲۳ میلیون
پاسخ‌ها	~۳۵ میلیون
بازدید ماهانه	~۱۰۰ میلیون

چرا SO برای تحقیق مناسب است؟

1. **داده‌ی عمومی:** Data Dump کامل در دسترس است
2. **تنوع رفتار:** از سؤال‌کننده تا متخصص، از روزانه تا سالانه
3. **تغییرات زمانی:** شاهد تغییرات عمده (ChatGPT، COVID) بوده
4. **اهمیت تجاری:** SO یک کسب‌وکار واقعی با نیاز به Retention است

۱.۲.۲ انواع فعالیت در SO

دسته	فعالیت‌ها
محتواسازی	Answer، Question
تعامل	Comment
کیفیت‌سنجی	Review، Flag، Tag، Edit
مدیریت	Close، Reopen، Delete، Protect

نکته‌ی مهم: Vote در Event Log ما نیست چون در داده‌های SO رأی‌دهنده مشخص نیست، فقط رأی‌گیرنده.

۱.۲.۳ سلسله‌مراتب اهمیت فعالیت‌ها

نه همه‌ی فعالیت‌ها برابر هستند:

$$\text{Importance}(\text{Answer}) > \text{Importance}(\text{Question}) > \text{Importance}(\text{Comment}) > \text{Importance}(\text{Edit})$$

فعالیت	Gain (وزن)	تأثیر بر جامعه	اهمیت در Churn
Answer	~0.16	بالا	بسیار بالا
Question	~0.09	متوسط	بالا
Comment	~0.06	پایین	متوسط
Edit	~0.05	متوسط	پایین

> **مثال مفهومی:**

> کاربری که روزانه **۵ پاسخ** با کیفیت می‌نویسد (مثل Gordon Linoff در حوزه‌ی SQL)، برای SO بسیار ارزشمندتر از کاربری است که روزانه **۵۰ نظر** می‌دهد. اگر اولی پاسخ‌نویسی را متوقف کند، زنگ خطر Churn باید به صدا درآید.

۱.۳ نمونه‌ی داده

۱.۳.۱ ساختار Data Dump

Stack Overflow Data Dump شامل چندین جدول XML است:

```
stackexchange-dump/
├── stackoverflow.com-Posts.7z          # سؤالات و پاسخ‌ها
├── stackoverflow.com-Comments.7z       # نظرات
├── stackoverflow.com-Users.7z          # اطلاعات کاربران
├── stackoverflow.com-Votes.7z          # رأی‌ها (استفاده نشد)
├── stackoverflow.com-PostHistory.7z    # تاریخچه‌ی ویرایش
└── stackoverflow.com-Badges.7z         # نشان‌ها
```

۱.۳.۲ نمونه‌ی رکورد کاربر

```xml
<row Id="12345"
     Reputation="5423"
     CreationDate="2015-03-15T10:30:00.000"
     DisplayName="JohnDev"
     LastAccessDate="2023-11-20T14:22:00.000"
     Location="San Francisco, CA"
     AboutMe="Software engineer. Python enthusiast."
     Views="1234"
     UpVotes="892"
     DownVotes="45"
     AccountId="67890" />
```

تجزیه‌ی این رکورد:

فیلد	مقدار	تفسیر
Reputation	5423	کاربر فعال با سابقه
CreationDate	2015-03	+۸ سال عضویت
LastAccessDate	2023-11	آخرین بازدید (نه آخرین فعالیت!)
UpVotes	892	رأی مثبت داده (نشان‌دهنده‌ی مشارکت)

۱.۳.۳ نمونه‌ی رکورد پست

```
<row Id="98765"
     PostTypeId="2"
     ParentId="98760"
     CreationDate="2020-06-15T08:45:00.000"
     Score="42"
     Body="&lt;p&gt;You can solve this by using..."
     OwnerUserId="12345"
     LastActivityDate="2020-06-20T12:00:00.000"
     CommentCount="3" />
```

فیلد	مقدار	تفسیر
PostTypeId	2	این یک Answer است (Question=1)
ParentId	98760	پاسخ به سؤال ۹۸۷۶۰
Score	42	۴۲ upvote خالص
OwnerUserId	12345	نویسنده

۱.۴ چالش‌های تعریف Churn

۱.۴.۱ چالش ۱: تعریف «فعالیت»

آیا همه‌ی فعالیت‌ها نشان‌دهنده‌ی Engagement هستند؟

```
# رویکرد ما: فعالیت‌های محتوایی + ویرایش
core_activities = ['question', 'answer', 'comment', 'edit', ...]
# Vote حذف شد چون رأی‌دهنده مشخص نیست
```

انتخاب ما: فعالیت‌هایی که Effort قابل‌توجه نیاز دارند و انجام‌دهنده مشخص است.

۱.۴.۲ چالش ۲: کاربران چندنوعی

یک کاربر ممکن است چندین «نقش» داشته باشد:

دوره	نقش	رفتار
2015-2017	Beginner	فقط سؤال می‌پرسد
2018-2019	Transition	شروع به پاسخ‌دهی
2020-2021	Expert	بیشتر پاسخ می‌دهد تا سؤال
2022-2023	Curator	فقط Edit و Review

> 💡 **مثال مفهومی:**

> کاربر **#12345** را در نظر بگیرید: در سال ۲۰۱۵ عضو SO شد و ۳۰ سؤال JavaScript پرسید. در ۲۰۱۸ شروع به پاسخ‌دهی کرد و ۲۰۰ پاسخ نوشت. در ۲۰۲۲ با 10K+ Rep دسترسی به Moderation Tools گرفت و بیشتر Edit و Review می‌کند. «عدم پاسخ‌دهی» برای او در ۲۰۱۸ نگران‌کننده بود، اما در ۲۰۲۳ طبیعی است چون نقشش عوض شده.

۱.۴.۳ چالش ۳: Temporal Drift

رفتار کاربران در طول زمان تغییر می‌کند:

دوره	رویداد	تأثیر بر SO
2016-2019	عادی	رشد پایدار
2020-2021	COVID-19	افزایش ۴۰٪ ترافیک، کاربران جدید
2022+	ChatGPT	کاهش سؤالات ساده، افزایش نرخ Churn

تأثیر بر مدل‌سازی:

$$P(\text{Churn}|\text{30 days inactive}, \text{Era} = 2019) \neq P(\text{Churn}|\text{30 days inactive}, \text{Era} = 2023)$$

۱.۵ پرسونای کاربران

۱.۵.۱ پرسوناها از کجا آمده‌اند؟

نکته‌ی مهم: پرسوناهای استفاده‌شده در این تحقیق، نتیجه‌ی یک **کار پژوهشی مستقل** هستند که قبلاً انجام شده است. در آن تحقیق، با استفاده از تکنیک‌های خوشه‌بندی و تحلیل رفتار کاربران ۲۰۰، Stack Overflow نوع کاربر متمایز شناسایی شد.

هدف آن تحقیق: درک اینکه کاربران Stack Overflow چه «شخصیت‌هایی» دارند — آیا همه یکسان‌اند یا گروه‌های متفاوتی وجود دارند؟

نتیجه: ۲۰ پرسونای متمایز شناسایی شد که از نظر:

- **سن و منطقه‌ی جغرافیایی** (جوانان آسیایی vs متخصصان آمریکایی)
- **سطح Reputation** (تازه‌کار vs خبره)
- **نوع فعالیت** (سؤال‌پرس vs پاسخ‌دهنده vs ویرایشگر)
- **الگوی زمانی** (روزانه vs هفتگی vs فصلی)

با هم فرق دارند. این پرسوناها در فایل `nmf_cluster_statistics_20.csv` ذخیره شده‌اند.

۱.۵.۲ چرا پرسونا برای Churn مهم است؟

یک آستانه‌ی Churn واحد برای همه کار نمی‌کند! فرض کنید:

نوع کاربر	رفتار عادی	اگر ۳۰ روز غایب باشد...
Power User (Jon Skeet)	روزانه فعال	🚨 **نگران‌کننده!** احتمالاً مشکلی پیش آمده
توسعه‌دهنده‌ی تازه‌کار	هفتگی	🟡 ممکن است طبیعی باشد
دانشجو	فقط در ترم‌ها	✅ کاملاً طبیعی — احتمالاً تعطیلات است
مدیر ارشد	ماهانه	✅ طبیعی — کاربران پرمشغله کمتر می‌آیند

نتیجه: باید برای هر پرسونا، آستانه‌ی جداگانه‌ای تعریف کنیم.

۱.۵.۳ روش شناسایی پرسونا: NMF

در تحقیق پیشین، از روش **NMF (Non-negative Matrix Factorization)** برای خوشه‌بندی کاربران استفاده شده است.

مثلاً) **به زبان ساده:** تصور کنید یک جدول بزرگ دارید که هر سطر یک کاربر و هر ستون یک ویژگی است **NMF** این جدول را «فشرده» می‌کند و کاربران مشابه را در گروه‌هایی کنار NMF .(سن عضویت، Answer تعداد، Reputation هم قرار می‌دهد.

$$\mathbf{V} \approx \mathbf{W} \cdot \mathbf{H}$$

نماد	معنی	توضیح ساده
$\mathbf{V}$	ماتریس اصلی	جدول کاربر-ویژگی (مثلاً ۹۲,۰۰۰ کاربر × ۱۵ ویژگی)
$\mathbf{W}$	عضویت در پرسوناها	هر کاربر چقدر به هر پرسونا شبیه است
$\mathbf{H}$	پروفایل پرسوناها	هر پرسونا چه ویژگی‌هایی دارد
$k = 20$	تعداد پرسوناها	۲۰ نوع کاربر متمایز

ویژگی‌های استفاده‌شده:

- Reputation، Upvotes، Downvotes، Views
- تعداد Badge، Comment، Answer، Question
- طول مدت فعالیت (total_duration)
- طول AboutMe (پروفایل)
- نسبت رفتار Collectivistic vs Individualistic

۱.۵.۴ پرسوناهای شناسایی‌شده (۲۰ کلاستر)

بر اساس تحلیل NMF روی داده‌های ۲۰۰۸ Stack Overflow، ۲۰ پرسونای متمایز شناسایی شد:

گروه ۱: کاربران جوان/تازه‌کار (۱۸-۲۴ سال)

Cluster	تعداد	منطقه	ویژگی کلیدی
15	2,449	—	Hobbyist (H)، Rep میانه ۴۰۳
7	3,535	اروپا	۱۸-۲۴ ساله، Rep میانه ۱۹۶
17	2,300	—	کم‌فعالیت، Rep میانه ۶۷

گروه ۲: متخصصان (۳۵-۴۴ سال)

Cluster	تعداد	منطقه	ویژگی کلیدی
12	3,668	آمریکای شمالی	Contributor (C)، Rep میانه ۷,۹۲۵
0	5,040	اروپا	۳۵-۴۴ ساله، Rep میانه ۲,۴۸۱
4	11,120	آمریکای شمالی	۳۵-۴۴ ساله، Rep میانه ۱,۸۴۸
11	1,241	آمریکای شمالی	Teacher (T)، Rep میانه ۴,۸۵۵

گروه ۳: کاربران آسیای جنوبی (۲۵-۳۴ سال)

Cluster	تعداد	منطقه	ویژگی کلیدی
10	13,508	آسیای جنوبی	۲۵-۳۴ ساله، Rep میانه ۴۷۶
1	9,746	آسیای جنوبی/شرقی	۲۵-۳۴ ساله، Rep میانه ۵۲۳
6	18,131	اروپا	۲۵-۳۴ ساله، Rep میانه ۵۷۶
3	2,663	آسیای جنوبی	Teacher (T)، Rep میانه ۱,۷۸۵

گروه ۴: کاربران حرفه‌ای با Rep بالا

Cluster	تعداد	ویژگی کلیدی	Rep میانه
2	2,639	Contributor (C)، اروپا	۶,۷۹۶
14	2,354	Contributor (C)	۴,۷۸۲
16	847	Teacher (T)	۳,۹۳۱
13	3,057	Teacher (T)، اروپا	۱,۹۴۴

گروه ۵: متخصصان/Influencer

Cluster	تعداد	ویژگی کلیدی	Rep میانه
9	859	Influencer (I) + Specialist	۲,۴۰۶
18	189	Influencer (I) + Specialist	۱,۳۸۳

گروه ۶: سایر

Cluster	تعداد	منطقه	Rep میانه
5	5,213	آمریکای شمالی	۳۰۳
8	1,870	—	۴,۰۰۶
19	1,421	آمریکای شمالی	۱,۸۹۱

۱.۵.۵ آمار کلی پرسوناها

شاخص	حداقل	حداکثر	میانگین
Rep میانه	۶۷	۷,۹۲۵	۲,۱۰۰
تعداد Answer میانه	۳	۱۳۶	۳۸
تعداد Question میانه	۲	۱۶	۸
تعداد Comment میانه	۳	۲۲۷	۵۵
مدت فعالیت میانه (ماه)	۱۰۵	۱۶۲	۱۴۰

۱.۶ فرمول‌بندی مسئله‌ی یادگیری ماشین

۱.۶.۱ ورودی‌ها

ورودی	نماد	ابعاد	توضیح
توالی رویدادها	$\mathbf{X}$	$(60, 8)$	۶۰ رویداد آخر × ۸ ویژگی
پرسونا	p	عدد صحیح	شماره‌ی پرسونا (۰ تا ۱۹)

۱.۶.۲ خروجی‌ها

خروجی	نماد	دامنه	توضیح
احتمال Churn	$\hat{y}_{churn}$	$(0, 1)$	هدف اصلی
پارامترهای Rule-based	T_p, A_p	مثبت	برای هر پرسونا جداگانه

۱.۶.۳ معیارهای ارزیابی

معیار	فرمول	چرا مهم است؟
Precision	$\frac{TP}{TP+FP}$	چند درصد از پیش‌بینی‌های Churn درست بود؟
Recall	$\frac{TP}{TP+FN}$	چند درصد از Churnerهای واقعی را پیدا کردیم؟
F1 Score	$\frac{2 \times P \times R}{P+R}$	تعادل بین Precision و Recall
AUC	Area Under ROC	عملکرد کلی در همه‌ی thresholdها

> 💡 **مثال مفهومی:**
>
> فرض کنید SO می‌خواهد به کاربران در خطر Churn ایمیل «برگرد!» بفرستد:

- **میزان Precision پایین:** به خیلی‌ها ایمیل می‌رود که اصلاً قصد ترک نداشتند ← آزاردهنده!
- **شاخص Recall پایین:** خیلی از Churnerها ایمیل نمی‌گیرند ← فرصت از دست می‌رود
- **مقدار F1 بالا:** تعادل خوب — ایمیل به افراد مناسب می‌رود

۱.۷ خلاصه‌ی فصل

۱.۷.۱ نکات کلیدی

1. ✅ **تشخیص Churn = عدم فعالیت پس از Grace Period**
2. ✅ **فرمول اولیه ساده:** `Churn if WA < Ap`
3. ✅ **فرمول نهایی:** با Grace Period و Observation Window
4. ✅ **پرسوناها از تحقیق قبلی آمده‌اند** (NMF، ۲۰ کلاستر)
5. ✅ **مشخصه Vote حذف شد** چون رأی‌دهنده مشخص نیست
6. ✅ **هر پرسونا آستانه‌ی متفاوتی نیاز دارد**

۱.۷.۲ ساختار فصل‌های بعدی

فصل	موضوع	هدف
۲	مهندسی داده	ساخت Event Log
۳	Rule-based	پیش‌بینی ساده با WA < Ap
۴	Enhanced WA	اضافه کردن trend و recency
۵	LSTM	یادگیری عمیق
۶	مقایسه	کدام بهتر است؟